
Lecture 4) Backpropagation and Neural Networks


· Lecture3 Review

$$s=f(x;W)=Wx$$
 scores function $L_i=\sum_{j
eq y_i}\max(0,s_j-s_{y_i}+1)$ SVM loss $L=rac{1}{N}\sum_{i=1}^NL_i+\sum_kW_k^2$ data loss + regularization want $\overline{
abla_WL}$


Backpropagation: Graph 계산하기




- 설명
 - 。 파랑: Matrix multiplication
 - 。 빨강: Data (loss) term
 - 。 녹색: Regularization term
- 네트워크 구조



- Backpropagation 계산
 - 。 Computational graph로 해석
 - 。 Chain rule을 사용



- gradient = local gradient * upstream gradient
 - local gradient: 현재 노드에서 계산한 gradient
 - upstream gradient: 이전 단계까지의 gradient
- 。 sigmoid gate 처럼, 원하는 연산을 모아놓을 수 있다.
- · Q. Gates?



- Max gate: Input 중에 큰 값을 내보내는 게이트. gradient router.
 큰 값이 최종 연산에 영향을 주었기 때문에, back prop에도 큰 값을 되돌려 보내는게 맞다.
- Add gate: gradient distributer
- o Mul gate: gradient switcher, scaler
- Jacobian matrix → diagonal matrix

Backpropagation 정리


- backprop는 gradient를 얻기 위한 주요한 방법
- forward: 결과를 얻기 위해 forward pass로 연산
- backward: chain rule을 사용하여 loss의 gradient를 계산한다.

Neural Network


• 식

(**Before**) Linear score function:
$$f=Wx$$
 (**Now**) 2-layer Neural Network or 3-layer Neural Network $f=W_3\max(0,W_1x)$


• 레이어를 쌓는 형태를 보인다.



- 。 계층적인 방식으로 쌓게 되고, 더 복잡하고 비선형적인 모델을 만들기 위함
- 비유



• 아키텍처



Activation function

- 비선형성을 부여. 뒤의 노드에 얼마나 큰 영향을 줄 것인지 결정하는 역할
- examples

Sigmoid
$$\sigma(x) = \frac{1}{1+e^{-x}}$$





tanh

tanh(x)

$$\begin{array}{l} \textbf{Maxout} \\ \max(w_1^Tx + b_1, w_2^Tx + b_2) \end{array}$$

ReLU

 $\max(0, x)$

$$\left\{ egin{array}{lll} x & x \geq 0 & & & \\ lpha(e^x-1) & x < 0 & & & \\ & & & & \end{array}
ight.$$